

DATA/RISK ANALYTICS CASE STUDY: XÂY DỰNG CREDIT SCORECARD CHO DANH MỤC TÍN DỤNG DƯỚI CHUẨN

1. Project Overview

Project: Xây dựng hệ thống Credit Scorecard nhằm đánh giá rủi ro tín dụng và hỗ trợ quyết định phê duyệt cho danh mục tín dụng dưới chuẩn.

Role: Data/Risk Analyst, phụ trách phân tích dữ liệu khách hàng, đánh giá chất lượng danh mục, phát triển mô hình Logistic Regression, chuyển đổi mô hình thành Credit Scorecard và đề xuất chính sách vận hành sau triển khai.

Business Problem: Danh mục tín dụng có tỷ lệ nợ xấu bình quân 21,5%, trong khi lãi suất cho vay chủ yếu nằm trong khoảng 10%–20%. Bài toán đặt ra là xác định liệu mức lợi suất hiện tại có đủ bù đắp rủi ro vỡ nợ hay không, đồng thời xây dựng một công cụ định lượng giúp phân loại khách hàng theo mức độ rủi ro.

Key Outcome: Mô hình Logistic Regression sử dụng biến WOE đạt $AUC = 0,7763$ và $KS = 0,4425$. Ngưỡng điểm sàn tối ưu được xác định ở mức 484, tương ứng $PD = 22,69\%$, từ đó hỗ trợ thiết kế khung phê duyệt phân tầng gồm phê duyệt tự động, định giá theo rủi ro và từ chối tự động.

2. Problem Framing & Data Understanding

Ở góc độ phân tích dữ liệu, mục tiêu đầu tiên của dự án là hiểu cấu trúc rủi ro của danh mục tín dụng tại ba thị trường và xác định các tín hiệu dữ liệu có thể giải thích khả năng vỡ nợ của khách hàng.

Phân tích mô tả cho thấy danh mục có tỷ lệ nợ xấu bình quân 21,5%, cao hơn mức thường thấy ở một danh mục tín dụng đại trà. Điều này cho thấy doanh nghiệp đang vận hành trong phân khúc rủi ro cao và cần một phương pháp ra quyết định dựa trên dữ liệu thay vì chỉ dựa vào quy tắc xét duyệt thủ công.

2.1. Data Validation

Trước khi mô hình hóa, tôi kiểm tra phân bố nhãn mục tiêu để xác nhận liệu tỷ lệ khách hàng xấu là đặc điểm thực tế của dữ liệu hay kết quả của các kỹ thuật cân bằng mẫu như undersampling hoặc SMOTE.

Kết quả Target Class Distribution cho thấy 21,54%% khách hàng thuộc nhóm xấu và 78,46% thuộc nhóm tốt. Việc xác nhận phân bố nhãn gốc giúp đảm bảo rằng các kết luận mô hình được xây dựng trên đặc điểm tự nhiên của danh mục, không bị sai lệch bởi thao tác tiền xử lý dữ liệu.

Từ góc nhìn Risk Analytics, phát hiện này rất quan trọng vì nó cho thấy mô hình cần được thiết kế để xử lý một danh mục có tỷ lệ rủi ro cao thực sự, đồng thời phải đảm bảo khả năng giải thích để hỗ trợ các quyết định tín dụng có tác động trực tiếp đến lợi nhuận và an toàn vốn.

3. Analytical Approach

Tôi tiếp cận bài toán như một dự án phân tích rủi ro tín dụng end-to-end, bắt đầu từ khám phá dữ liệu, kiểm định chất lượng dữ liệu, phát triển mô hình, đánh giá hiệu năng và cuối cùng là chuyển kết quả mô hình thành quy tắc vận hành có thể áp dụng trong quy trình phê duyệt.

Mô hình chính được lựa chọn là Logistic Regression do phù hợp với yêu cầu giải thích trong lĩnh vực tín dụng. Các biến đầu vào được mã hóa bằng WOE nhằm tăng tính đơn điệu, cải thiện khả năng diễn giải và hỗ trợ chuyển đổi kết quả mô hình thành hệ thống điểm tín dụng.

Bộ đặc trưng cuối cùng gồm 11 biến phản ánh các khía cạnh chính của hồ sơ tín dụng, bao gồm khả năng trả nợ, thu nhập, nghĩa vụ nợ và mức độ nhạy cảm tài chính. Tôi kiểm soát đa cộng tuyến bằng VIF và tinh chỉnh bộ biến để toàn bộ đặc trưng đạt VIF dưới 2,5, giúp mô hình ổn định hơn khi triển khai.

3.1. Model Explainability & Scorecard Calibration

Trong quá trình chuyển đổi mô hình sang scorecard, tôi phát hiện một vấn đề liên quan đến hướng tác động của WOE: nếu công thức quy đổi điểm không được hiệu chỉnh đúng, nhóm khách hàng có rủi ro cao có thể nhận điểm cao hơn nhóm rủi ro thấp. Đây là vấn đề nghiêm trọng vì làm giảm tính hợp lý nghiệp vụ và khả năng giải trình của mô hình.

Tôi hiệu chỉnh công thức chuyển đổi điểm để đảm bảo quan hệ nhất quán giữa rủi ro và điểm tín dụng: xác suất vỡ nợ càng cao thì điểm tín dụng càng thấp. Việc này giúp scorecard vừa giữ được nền tảng thống kê của mô hình, vừa phù hợp với logic xét duyệt tín dụng trong thực tế.

4. Results, Metrics & Business Impact

Mô hình đạt $AUC = 0,7763$ và $KS = 0,4425$, cho thấy khả năng phân biệt tương đối tốt giữa khách hàng tốt và khách hàng xấu. Đây là mức hiệu năng phù hợp để sử dụng scorecard như một công cụ hỗ trợ quyết định trong quy trình phê duyệt tín dụng.

Dựa trên phân tích ma trận nhầm lẫn, tôi xác định ngưỡng điểm sàn tối ưu là 484, tương ứng $PD = 22,69\%$. Ngưỡng này được sử dụng như điểm hòa vốn rủi ro để phân tách các nhóm khách hàng có khả năng tạo giá trị kinh tế khác nhau cho danh mục.

Khi so sánh PD hòa vốn $22,69\%$ với tỷ lệ nợ xấu thực tế $21,5\%$, danh mục chỉ còn vùng đệm khoảng 1,19 điểm phần trăm. Insight này cho thấy doanh nghiệp đang vẫn đang vận hành trong giới hạn chấp nhận được, nhưng dư địa an toàn không lớn và cần có cơ chế kiểm soát chặt hơn đối với nhóm khách hàng rủi ro cao.

Phân tích theo hạng điểm cho thấy nhóm hạng G có tỷ lệ default lên tới $98,44\%$, vượt xa khả năng bù đắp của bất kỳ mức biên lãi suất trần nào trong phân khúc dưới chuẩn (dù lãi

suất toàn danh mục bình quân là 11%). Đây là một insight quan trọng để đề xuất cơ chế từ chối tự động hoặc tái định giá rủi ro nghiêm ngặt đối với phân khúc này.

Về tác động kinh doanh, dự án chuyển đổi kết quả mô hình từ một chỉ số thống kê thành khuyến nghị hành động cụ thể: xác định nhóm khách hàng có thể phê duyệt nhanh, nhóm cần định giá lại theo rủi ro và nhóm cần loại trừ để bảo vệ chất lượng danh mục.

5. Recommendations & Monitoring Framework

5.1. Risk-Based Approval Strategy

Low-risk segment ($PD \leq 15\%$): Đề xuất áp dụng phê duyệt tự động nhằm rút ngắn thời gian xử lý hồ sơ, cải thiện trải nghiệm khách hàng và giảm chi phí thẩm định thủ công.

Medium-risk segment ($15\% < PD \leq 22,69\%$): Tiếp tục xem xét phê duyệt nhưng áp dụng risk-based pricing. Biên lãi suất nên được điều chỉnh tăng khoảng 1,5%–3%, đồng thời bổ sung điều kiện kiểm soát như giới hạn tỷ lệ nghĩa vụ nợ trên thu nhập.

High-risk segment ($PD > 22,69\%$): Đề xuất từ chối tự động để hạn chế tổn thất kỳ vọng vượt quá khả năng bù đắp của lợi suất danh mục.

“Lưu ý vận hành: Khung phê duyệt này được khuyến nghị triển khai theo lộ trình cuốn chiếu (Phased Rollout), ưu tiên cô lập nhóm Hạng G trước, sau đó siết dần biên độ kiểm soát tệp Hạng F để phòng Kinh doanh kịp thích nghi và tránh sụt giảm doanh số đột ngột.”

5.2. Post-Deployment Monitoring

Để đảm bảo mô hình duy trì hiệu quả sau triển khai, tôi đề xuất theo dõi chỉ số PSI nhằm phát hiện dịch chuyển dữ liệu. Với PSI hiện tại ở mức 0,0016, quần thể khách hàng mới được đánh giá là ổn định; tuy nhiên, cần thiết lập ngưỡng cảnh báo và tạm dừng phê duyệt tự động khi PSI vượt 0,25.

Ngoài PSI, tôi đề xuất theo dõi định kỳ AUC, KS, tỷ lệ default thực tế và phân bố điểm theo từng quý. Khi hiệu năng mô hình suy giảm hoặc đặc điểm khách hàng thay đổi đáng kể, quy trình tái huấn luyện cần được kích hoạt để duy trì độ chính xác và tính ổn định của scorecard.

6. Key Takeaways for Data/Risk Analyst Role

Case study này thể hiện năng lực triển khai một bài toán phân tích dữ liệu từ đầu đến cuối: hiểu bối cảnh kinh doanh, kiểm định dữ liệu, xây dựng mô hình, đánh giá hiệu năng, diễn giải kết quả và chuyển insight thành khuyến nghị vận hành.

Đối với vai trò Data Analyst hoặc Risk Analyst, giá trị chính của dự án nằm ở khả năng kết nối giữa phân tích định lượng và quyết định kinh doanh. Thông qua Credit Scorecard, dự án giúp doanh nghiệp cân bằng giữa tăng trưởng tín dụng, kiểm soát rủi ro và bảo vệ an toàn vốn bằng một framework có thể đo lường và giám sát sau triển khai.

Skills demonstrated: Data validation, exploratory data analysis, credit risk modeling, WOE transformation, Logistic Regression, scorecard calibration, model evaluation, business insight generation and risk-based recommendation.